

Création d'une application pour la génération de triplets Wikidata pour les entités

Logiciel de désambiguïsation des entités nommées

Approche par Traitement Automatique du Langage Naturel

Wikidata et SPARQL

Falcão Barreto, Felipe Mateus
Mounsif, Najib
Ramdan, Taha


Résumé

Ce rapport présente le développement d'une application d'extraction de connaissances à partir d'entités nommées présentes dans les titres scientifiques. Partant du principe qu'il n'existe pas de méthode largement répandue pour automatiser ce processus, le logiciel se veut intuitif et facile d'utilisation, générant des informations pertinentes et aisément compréhensibles.

1. Contexte et Problématique

1.1 Introduction

Avec des investissements de 33,94 milliards de dollars en 2024, contre moins de 5 milliards par an jusqu'en 2022, cette hausse s'explique en grande partie par le lancement récent de technologies d'intelligence artificielle (IA) entre le début de l'année 2022 et 2023, telles que ChatGPT, ClaudeAI et Gemini. Ainsi, bien que la recherche en IA générative soit menée depuis de nombreuses années, cet outil n'a acquis popularité et fiabilité que récemment. Son potentiel de développement est donc considérable.



Face à cette croissance, le traitement automatique du langage naturel (LLM) et la modélisation du langage à grande échelle (MLGE) prennent une importance croissante dans la résolution de problèmes grâce à des modèles basés sur l'apprentissage profond et les réseaux de neurones. Par conséquent, l'amélioration des techniques de traitement et d'interprétation du texte afin de répondre précisément aux besoins des utilisateurs devient primordiale.

Cependant, bien que des outils existent pour résoudre ce problème, il manque des applications qui simplifient ce processus. Des outils tels que Docling, qui structure le texte, et SpaCy, qui effectue la reconnaissance d'entités nommées (NER) et la désambiguïsation d'entités nommées (NED), et qui relie ces entités à des bases de connaissances externes, fonctionnent indépendamment, sans solution unifiée.

Ce processus constitue une étape cruciale pour l'enrichissement des modèles de

génération augmentée par la recherche (RAG), qui unifie l'enrichissement du langage naturel et des données externes. Dans ces modèles, l'enrichissement de la base de données de l'IA avec des données externes rend le processus de génération automatique de réponses plus précis par rapport aux requêtes des utilisateurs, ce qui rend l'IA plus adaptable à différents scénarios.

Parmi les bases de données externes possibles, on trouve Wikidata, la base de données Wikipédia. Contrairement aux langages de requêtes structurées (SQL) classiques qui utilisent des requêtes basées sur des tables structurées, cette base de données utilise SPARQL, qui fonctionne avec des triplets sujet-prédicat-objet. Cet outil facilite la génération de graphes et de triplets de connaissances.

Ce projet s'inscrit dans ce contexte. Initialement conçu pour faire l'impasse sur la structuration du texte et exécuter la phase de la NER, il se concentre sur la phase de mise en œuvre de la MER, en communiquant avec l'API Wikidata pour extraire des connaissances via des requêtes SPARQL et générer des triplets. Les données obtenues sont ensuite traitées et stockées dans une base de données afin de classer les triplets grâce à un modèle entraîné capable de déterminer ceux qui présentent la relation sémantique la plus proche du texte original. Enfin, un fichier texte et un graphique aux formats PNG et PDF sont générés pour permettre la visualisation des triplets filtrés et ordonnés.

1.2 Définition Formelle du Problème

Le projet est formalisé comme un problème d'extraction de connaissances externes visant à filtrer et ordonner des triplets en fonction de leur similarité sémantique avec le texte original. Le processus comprend :

- Génération de triplets via des requêtes SPARQL à l'API Wikidata.
- Nettoyage et filtrage des triplets pertinents.
- Génération et classement des triplets les plus pertinents à l'aide d'un modèle intégrant des embeddings et des encodeurs.
- Retour à l'utilisateur au format texte et sous forme de graphe structuré.

1.2 Outils utilisés

Pour le développement de l'application, les éléments suivants ont été utilisés :

Comme demandé, la bibliothèque SPARQL a été utilisée pour les requêtes de données externes. Pour les données et bases de données internes, FlaskAPI a d'abord été utilisé, mais après discussion au sein de l'équipe, il a été remplacé par FastAPI en raison de sa simplicité de mise en œuvre.

Enfin, pour les données générales, scikit-learn, spaCy et plusieurs autres bibliothèques ont été utilisées.

La liste complète suit :

Frontend: Angular, core, router, common, http, forms, typescript, scss
Backend et serveur: FastAPI, SPARQLWrapper
Data & AI: SpaCy, sentence_transformers, numpy, sklearn, pandas, matplotlib

2. Analyse des Données Sources

2.1 Vue d'Ensemble du Jeu de Données

Le jeu de données de base servant à structurer la base de données de l'application contenait des données de requêtes de base issues de Wikidata. Il s'agissait du fichier CSV "DBLP1_processed_.csv" qui contenait 3065 requêtes possibles.

Indicateur	Valeur Obtenue
Volume de données traitées	723 KB
Volume de données observées	3065

2.2 Structure Détaillée du Tableau

Champ	Type	Description
Title	string	Texte principal servant de base à chaque requête.
l1Num	int	Il divise chaque requête en groupes. Non utilisée dans ce projet.
QID	list[int]	Identifiant de chaque entité dans Wikidata
Labels	list[string]	Étiquette de chaque entité dans Wikidata

2.3 Analyse de Qualité des Données

Une analyse générale des données révèle plusieurs problèmes de qualité qui nécessitent un traitement spécifique:

1. Extraction et désambiguïsation d'entités: L'identifiant et l'étiquette sont indépendants, sans aucun lien mutuel.
2. Format de champ ID invalide: les requêtes Wikidata doivent commencer par un 'Q' suivi de l'identifiant (par exemple, France = Q142).
3. Validation des identifiants: nettoyage des données par vérification de l'existence de tous les identifiants dans Wikidata.

3. Traitement des données

Dans cette partie nous avons réalisé l'extraction des entités, Cette étape permet non seulement de repérer les termes importants, mais aussi de les relier à une base de connaissances externe, dans notre cas c'est WIKIDATA. Chaque entité donc détectée est alors associée à un identifiant unique appelé QID.

3.1 Principe de l'approche

Dans notre traitement, nous avons suivi une logique étape par étape. D'abord, nous sommes partis du texte brut, c'est-à-dire les titres scientifiques. Ensuite, nous avons extrait les entités importantes présentes dans ces titres. Une fois ces entités détectées, nous les avons reliées à Wikidata pour récupérer des informations supplémentaires sous forme de triplets.

Après cela, nous avons transformé les identifiants techniques en labels lisibles, afin que les résultats soient compréhensibles pour l'utilisateur. Enfin, nous avons représenté ces connaissances sous forme de graphe, pour visualiser plus facilement les liens entre le document, les entités, les relations et les objets associés.



3.2 Extraction et normalisation des entités

Après l'**Entity Linking**, chaque titre donne une liste d'entités détectées. Par exemple, un titre peut contenir des entités comme *document*, *organization*, *expert* ou *solution*. Ensuite, chaque entité est reliée à son identifiant Wikidata, appelé **QID**, pour pouvoir être utilisée dans les requêtes **SPARQL**.

Dans notre expérimentation, nous avons nettoyé et regroupé ces QID afin d'éviter les doublons. Au total, le système a identifié **3086 entités uniques**. Ces entités ont ensuite servi de base pour interroger Wikidata et enrichir les titres scientifiques avec des connaissances externes.

Indicateur	Valeur Obtenue
Entités uniques détectées	3086
Échantillon utilisé pour l'extraction SPARQL	50 entités
Triplets extraits et labellisés	5363

3.2 Extraction des triplets depuis Wikidata

Pour chaque entité retenue, le système interroge Wikidata via les requêtes SPARQL. Les résultats sont obtenus sous forme de triplets c'est à dire une structure composée de trois éléments :



Par exemple, un triplet technique extrait depuis Wikidata peut être écrit sous la forme :

Q2 — P31 — Q3504248.

Ce format est utile pour la machine, mais difficile à lire pour un utilisateur. Une étape de labellisation transforme donc ce triplet en une forme plus claire :




Sujet	Relation	Objet
Earth	instance of	inner planet of the Solar System
Earth	part of	Solar System
Earth	location	Milky Way

Cette technique permet de passer d'une représentation technique basée sur des identifiants Wikidata à une représentation simple compréhensible par l'humain.

3.3 Construction du graphe de connaissances

À la fin, nous avons choisi de représenter les triplets sous forme de **graphe de connaissances** pour rendre le résultat plus facile à lire. Le document est placé au centre, puis il est relié aux entités détectées. Chaque entité est ensuite reliée à ses relations et aux informations associées.

Pour faciliter la compréhension, nous avons utilisé des couleurs différentes : le vert pour le document, l'orange pour les entités, le jaune pour les relations et le bleu pour les objets. Cette visualisation permet de comprendre rapidement les liens entre les éléments, au lieu de lire une longue liste de triplets.



Ainsi, cette partie **Avant la partie filtrage** ne se limite pas à extraire automatiquement des entités. Elle permet de transformer progressivement un titre scientifique en connaissances structurées, enrichies grâce à **Wikidata**, puis visualisées sous forme de graphe.

Cela rend les résultats plus clairs, plus faciles à interpréter et plus accessibles pour l'utilisateur final.

4. Modélisation

Dans un premier temps, une approche axée sur les fonctions de similarité cosinus était nécessaire, mais en raison d'un manque de résultats concrets indiquant un succès ou un échec, il a été nécessaire de suivre une approche expérimentale, en appliquant diverses techniques d'entraînement utilisées dans des modèles similaires pour enrichir le modèle.

Le modèle développé repose donc sur une approche hybride combinant trois modèles: le cross-encoder, la similarité cosinus et la similarité d'entités. Chacun sera détaillé ci-dessous.

Initialement, après le traitement des données et la construction des triplets, le modèle applique une représentation vectorielle des textes grâce à l'utilisation d'embeddings. Cette conversion est appliquée au titre, aux triplets, aux entités et à l'objet, et facilite l'utilisation des techniques de similarité cosinus et d'entités via la technique du bi-encodeur. Cette dernière consiste à calculer indépendamment la similarité entre deux textes en divisant le produit scalaire des vecteurs par le produit de leurs normes. Dans le premier cas, ce calcul est effectué entre le triplet et le titre d'entrée, tandis que dans le second, il s'agit de calculer la similarité maximale entre le titre et le sujet ou entre le titre et l'objet.

Ensuite, un cross-encoder est également appliqué, qui, contrairement aux méthodes précédentes, évalue directement le titre et la paire de triplets, en traitant les deux ensemble et en permettant une estimation plus précise de la pertinence.

Chaque score a été traité et soumis à une normalisation min-max, permettant une comparaison équitable. En effet, les fonctions cosinus varient de -1 (valeurs différentes) à 1 (valeurs égales), tandis que l'échelle de le cross-encoders dépasse ces valeurs, conformément au principe de positivité pour les valeurs similaires et de négativité pour les valeurs différentes. De plus, une combinaison pondérée a été appliquée, selon la formule ci-dessous:

$$\text{poids} = 0,75 + 0,25 * \text{poids du pr\u00e9dicat}$$

Ensuite, une pond\u00e9ration s\u00e9mantique des relations a \u00e9t\u00e9 appliqu\u00e9e, en filtrant manuellement les pr\u00e9dicats pr\u00e9sentant la plus grande similarit\u00e9, en leur attribuant des poids de 1.25, 1.10, 1, 0.85 et 0.6 en fonction de leur pertinence, et en proc\u00e9dant \u00e9galement \u00e0 un processus de normalisation, comme suit:

$$\text{score} = \text{base} * \text{poids}$$

Poids de chaque pr\u00e9dicat (1,00 \u00e9tant le poids de base):

- Poids \u00e9gal \u00e0 1,25: "use", "apply", "based on", "develop", "affect", "cause", "study", "model"
- Poids \u00e9gal \u00e0 1,10: "part of", "has", "related", "contains"
- Poids \u00e9gal \u00e0 0,85: "instance of", "subclass of"
- Poids \u00e9gal \u00e0 0,60: "wikimedia", "template", "category", "described by source", "focus list", "maintained by", "same as", "coincident", "outline", "topic"

\u00c9tant donn\u00e9 que la somme finale de chaque triplet est le produit de la valeur de base par son poids, c'est-\u00e0-dire:

$$\text{base} = (0,45 * \text{score cosinus} + 0,35 * \text{cross score} + 0,20 * \text{score d'entit\u00e9})$$

Enfin, des filtres de triplets dupliqu\u00e9s et une validation de triplets ont \u00e9t\u00e9 appliqu\u00e9s (en \u00e9vitant les valeurs nulles ou invalides dans les triplets), classant ainsi les N premiers (valeurs attribu\u00e9es par l'utilisateur) les plus s\u00e9mantiquement similaires au titre.

5. R\u00e9sultats et Analyse

5.1 Retour \u00e0 l'utilisateur

Le syst\u00e8me d\u00e9velopp\u00e9 g\u00e9n\u00e8re deux principaux types de repr\u00e9sentation des donn\u00e9es en sortie : des graphes de connaissances et des fichiers texte structur\u00e9s. Ces deux formats permettent \u00e0 la fois la visualisation interpr\u00e9table des relations entre les entit\u00e9s et l'analyse quantitative des r\u00e9sultats class\u00e9s par le mod\u00e8le.

Initialement, les triplets extraits et class\u00e9s sont stock\u00e9s dans des variables de requ\u00eate qui contiennent les triplets et leurs scores, puis regroup\u00e9s par sujet. Ce regroupement permet de comprendre quelles relations sont les plus pertinentes pour chaque entit\u00e9 au sein d'une requ\u00eate sp\u00e9cifique. Les donn\u00e9es relatives aux triplets, aux scores, aux identifiants et aux \u00e9tiquettes sont stock\u00e9es dans la base de donn\u00e9es, ce qui permet de consulter \u00e0 nouveau les donn\u00e9es de chaque requ\u00eate, ainsi que de r\u00e9utiliser les sujets dans de nouvelles requ\u00eates, \u00e9vitant ainsi une consommation excessive de l'API Wikidata.

5.1 Génération de graphiques

L'étape de visualisation transforme les triplets en un graphe orienté hiérarchique, où le nœud central représente le document (titre de la requête) et chaque nœud suivant représente respectivement le sujet, le prédicat et l'objet. Ce processus crée une structure arborescente organisée latéralement.

Le filtrage sémantique supprime les nœuds génériques non pertinents (tels que "entity", "object", "concept"), améliorant ainsi la clarté du graphe. Les prédicats les plus importants (par exemple "instance of", "part of", "use") sont prioritaires dans l'ordre visuel, garantissant que les relations les plus informatives soient plus proches du centre.

Le résultat final est un graphe exportable aux formats PNG et PDF, permettant une utilisation académique et une analyse exploratoire.

5.2 Génération de fichier texte

Le système génère également une version textuelle des triplets, où chaque relation est représentée par un texte continu, comme dans l'exemple suivant:

France capital Paris

Ce format est utilisé à la fois pour le stockage dans la base de données et pour le retour des triplets générés, permettant ainsi de visualiser le nombre, la nature et le classement des triplets extraits.

5.3 Analyse et limites de la qualité des résultats

L'un des principaux défis du système réside dans la qualité des triplets extraits et filtrés. Les données provenant de Wikidata via SPARQL, toutes les relations ne sont pas nécessairement pertinentes pour le contexte de la requête. C'est pourquoi l'étape de classement et de filtrage est essentielle.

Cependant, l'évaluation des résultats est complexifiée par l'absence de critère empirique de pertinence, car:

- tous les triplets extraits ne sont pas sémantiquement corrects pour la tâche.
- il n'existe pas de distinction claire entre les relations pertinentes et non pertinentes avant le classement.
- La pertinence dépend fortement du contexte de la requête.

Par conséquent, le système utilise un filtre indirect basé sur des modèles de similarité (similarité cosinus, encodeur croisé et similarité d'entités), qui permettent d'approcher les résultats de ce qui serait considéré comme "pertinent", sans toutefois éliminer complètement le bruit sémantique.

Sans un filtrage préalable rigoureux des triplets corrects et incorrects, l'évaluation finale peut être biaisée, car:

- le modèle peut bien classer des données non pertinentes en se basant uniquement sur leur similarité textuelle
- les graphes peuvent contenir des relations structurellement valides, mais sémantiquement inutiles pour la tâche.

Ainsi, la qualité des résultats dépend directement de la combinaison des processus d'extraction, de filtrage et de modélisation des données.

6. Autres outils auxiliaires développées

6.1 Structure de la base de données

entities:

Nom	Description
qid	ID de l'entité (sujet ou prédicat)
label	Étiquette d'entité

entity_cache:

Nom	Description
qid	ID de l'entité (sujet ou prédicat)
fully_loaded	Indicateur booléen qui enregistre si tous les triplets ont été sauvegardés lors de l'importation des données.
last_updated	Date de la dernière mise à jour
triplet_count	Triplet total

entity_favorites

Nom	Description
qid	ID de l'entité (sujet ou prédicat)

predicates:

Nom	Description
qid	ID de prédicat
label	Étiquette de prédicat

queries:

Nom	Description
id	ID de l'entité (sujet ou prédicat)
title	Étiquette d'entité
hops	Analyse plus approfondie du nombre de nœuds dans la requête. Il a été demandé de ne pas utiliser cet outil.
top_n	Filtre de taille de classement
created_at	Date de création
favorite	Requêtes favorites

query_results:

Nom	Description
id	ID de triplet de table
triple	Triplet complet
query_id	ID de requête
subject_qid	ID du sujet
predicate_pid	ID de prédicat
object_qid	ID d'objet
score	Résultat triplet

settings

Nom	Description
key	clé pour chaque configuration (default_hops et default_top_n)
value	Valeur de chaque configuration

6.2 Scripts développés

- create_schema.py: Création de base de données
- import_data.py: Importation des données (validation de l'existence de ces données dans la base de données)

6.3 Pages développées

Les pages suivantes ont été développées et sont disponibles en pièce jointe.

Nom	Description
Home	Page principale
New Query	Vous pouvez renseigner les informations de la nouvelle requête.
Query Generated	Visualisation de la requête générée (sans spécifier d'ID)
Search Entities	Recherche d'entité
Entity Data	Données d'entité
Top Queries	Données auxiliaires issues des requêtes (entités les plus utilisées, prédicats les plus utilisés et triplets ayant le score le plus élevé)
Last Queries	Visualisation des requêtes effectuées
Query Data	Affichage des données de la requête (avec ID spécifié)
Settings	page des paramètres (définition des valeurs par défaut et suppression de toutes les requêtes)

Remarque : Comme indiqué, l'utilitaire "Hops" a été initialement développé, mais ses fonctionnalités n'ont pas été implémentées de manière continue comme prévu.

7. Organisation et gestion de projet

Pour mener à bien ce projet dans les délais impartis, un calendrier des tâches a été établi afin de garantir des objectifs clairs et partagés pour chaque phase.

La deuxième étape a consisté à subdiviser les tâches : un diagramme de Gantt a été créé (disponible en annexe), attribuant à chaque membre de l'équipe une phase distincte par semaine.

Des réunions hebdomadaires régulières ont également été organisées pour faire le point sur l'avancement de chacun.

8. Conclusion et Perspectives

Ce travail démontre qu'il est possible de structurer les connaissances à partir de données semi-structurées, en transformant des triplets extraits de Wikidata en représentations organisées, interprétables et hiérarchisées. L'utilisation de graphes permet une visualisation claire des relations entre les entités, tandis que la sortie textuelle assure la traçabilité et l'analyse quantitative des résultats. Ainsi, l'hypothèse selon laquelle l'automatisation de l'extraction de triplets contribue à la construction de connaissances structurées est confirmée.

Cependant, le système présente des limitations importantes, principalement dues à sa forte dépendance à la qualité des requêtes externes via SPARQL et aux données disponibles dans Wikidata. De plus, l'absence d'un filtre sémantique initial robuste implique que l'évaluation des résultats dépend fortement du modèle de classement, ce qui peut impacter la pertinence finale des triplets sélectionnés. Ceci souligne l'importance des étapes de prétraitement et de normalisation des données dans le processus.

Les perspectives futures incluent l'optimisation du système pour traiter de grands volumes de données et l'intégration de modèles plus avancés afin d'améliorer le filtrage et le classement. De plus, l'intégration de techniques de structuration des données avec Docling et de NER avec SpaCy, en complément de l'outil Hops, enrichirait le projet.

Enfin, ce projet a permis d'approfondir significativement les connaissances en techniques d'intégration, en modèles basés sur les transformeurs et en utilisation des requêtes SPARQL, consolidant ainsi des compétences essentielles à l'intersection de l'ingénierie, des sciences et de l'analyse des données dans les systèmes pilotés par les données.

9. Annexe

9.1 Diagramme de Gantt

Group members	Week 1	Week 2	Week 3	Week 4
Felipe	Triplet extraction in Wikidata	NLP model development and text file generation	New model integration	Entities data page
Najib	Initialization of app dependencies	New query page development	All entities page	Bug refactor
Taha	Entity linker and graph generation model	Home and settings page development	All queries page	Bug refactor

9.2 Pages développées

Home:



Sidebar:



New Query:

New Query

Upload CSV
 test_dfp.csv

Number of Hops

Number of Triples

[Back](#) [Execute Query](#)

Query Generated:



Search Entities:

Search Entities

[+](#)

QID #	Label #	Occurrences #	Favorite	Visualize
Q142	France	2	★	Visualize
Q5119	capital city	2	☆	Visualize
Q1200750	description	1	★	Visualize
Q56778	system	1	☆	Visualize
Q817433	Syracuse University	1	☆	Visualize
Q19878146	Extraction	1	☆	Visualize
Q65071491	Word	1	★	Visualize
Q45025858	depicting object	0	☆	Visualize
Q115491417	description	0	☆	Visualize
Q61070632	Besque Literature Terms Dictionary	0	☆	Visualize

Entity data:

Entity: Q1200750

Occurrences: 1

Title	Hops	Date	Expand	Visualize
A description is given of FPPlus	1	29/04/2026 08:43:17	Expand	Visualize

Top Queries:

Top Queries Dashboard		
Top Subjects		
Subject	Count	Percentage
Math	150	25%
Science	120	20%
History	80	13%
Language Arts	70	12%
Physical Education	50	8%
Art	30	5%
Music	20	3%
Top Practises		
Practise	Count	Percentage
Reading Comprehension	180	30%
Writing	150	25%
Math	120	20%
Science	100	17%
History	80	13%
Language Arts	70	12%
Physical Education	50	8%
Art	30	5%
Music	20	3%
Top Topics		
Topic	Count	Percentage
Algebra	100	17%
Geometry	80	13%
Calculus	60	10%
Statistics	40	7%
Trigonometry	30	5%
Number Theory	20	3%
Mathematical Logic	10	2%

Last Queries:

emU


Last Queries

(3/7) / 3/3/3
(3/7) / 3/3/3

Title	Hops	Triples	Date	Favorite	Visualizer	Delete
What is the capital of France?	1	6	04/05/2020 04:51:08			
What is the capital of France?	1	10	03/05/2020 22:25:19			
WeIRD is an automatic document retrieval system designed a...	1	23	03/05/2020 04:19:50			
In information Extraction	1	10	03/05/2020 03:25:52			
A description is given of FPlus	1	4	29/04/2020 09:43:17			

Page 1

Query Data:



Settings:

 amU

Settings

Default Hops

Default Top Triplets

 Save

 Clear All Quizzes

Sources bibliographiques:

Stanford Institute for Human-Centered Artificial Intelligence. *AI Index Report 2025 – Economy*. 2025. Disponible à l'adresse : <https://hai.stanford.edu/ai-index/2025-ai-index-report/economy>. Consulté le 4 mai 2026.